Sistemas de Alerta Temprana (EWS) para Prevención de Deserción

Informe Técnico de Revisión de Literatura & Propuesta de Arquitectura de Software

Resumen Ejecutivo: Este informe condensa la revisión sistemática de literatura científica y patentes internacionales sobre Sistemas de Alerta Temprana (EWS) para la retención estudiantil. Integra un análisis riguroso de variables de entrada, algoritmos de Machine Learning y una propuesta de arquitectura de software optimizada para su implementación por el semillero de investigación.

1. PARTE I: REVISIÓN DE LITERATURA Y CIENCIA DE DATOS

1.1 Catálogo Exhaustivo de Variables de Entrada (Features)

A partir de la revisión sistemática de las 10 fuentes seleccionadas, las variables de entrada utilizadas en los modelos predictivos de deserción se categorizan en 5 dimensiones clave:

- **Historial Académico y Rendimiento Previo/Universitario:** Promedio de notas de secundaria (High School GPA), puntajes de exámenes de admisión, condición de admisión (regular o condicional), GPA/IPK acumulado universitario, créditos/asignaturas reprobadas y repetidas, calificaciones de evaluaciones continuas (CAA) y porcentaje de asistencia.
- **Datos Socio-demográficos y Contextuales:** Edad al momento de la matrícula, género, nacionalidad, tipo de colegio de origen, nivel educativo de los padres, ocupación de los padres, responsabilidades familiares, índice de privación del código postal y tiempo/medio de transporte a la institución.
- **Información Financiera y Becas:** Estado de pago de matrícula (al día o en mora), fuentes de financiamiento, tenencia de becas o auxilios institucionales, préstamos estudiantiles (federales o privados) e indicadores de tensión económica.
- **Interacción Digital en LMS (Clickstream Data):** Frecuencia de inicios de sesión en plataformas (Moodle, Canvas, VLE), tiempo de permanencia por sesión, patrones de accesos a recursos didácticos, registros de IP, estampas de tiempo (timestamps) y participación en foros (mensajes leídos/publicados).
- **Datos Cualitativos (Texto No Estructurado) y Factores Perceptuales:** Texto libre de evaluaciones docentes, actas/notas de texto de sesiones de consejería y tutoría, encuestas de integración social y salud mental, percepción de orientación vocacional y horas dedicadas a actividades extracurriculares o voluntariado.

1.2 Evaluación Técnica de Algoritmos de Machine Learning y Modelos Matemáticos

A continuación se evalúan los modelos y enfoques algorítmicos documentados en las fuentes, detallando sus ventajas y desventajas metodológicas:

- **Random Forest (RF):**

Ventajas: Excelente capacidad para capturar interacciones no lineales entre variables heterogéneas; reduce sobreajuste mediante bagging; proporciona métricas directas de importancia de variables (Gini Impurity).

Desventajas: Naturaleza de caja negra dificulta la interpretación causa-efecto pedagógica directa; susceptible a optimizar exactitud general descuidando la clase minoritaria (deserción) en datos desbalanceados.

- **XGBoost / LightGBM (Gradient Boosting):**

Ventajas: Logra la mayor precisión y sensibilidad (Recall de 88% a 91%) en datos tabulares de ingreso; integración fluida con SHAP para explicabilidad local/global; permite calibrar el umbral de decisión (cutoff).

Desventajas: Computacionalmente intensivo; requiere ajuste fino riguroso de hiperparámetros (learning rate, max depth) para evitar sobreajuste en muestras pequeñas.

- **Redes Recurrentes (LSTM / GRU):**

Ventajas: Captura la dinámica temporal y las tendencias de compromiso decreciente en datos de LMS a lo largo de las semanas.

Desventajas: Alto costo computacional; difícil interpretación de pesos internos para justificar alertas ante asesores pedagógicos.

- **Modelos Híbridos Transformer (KoBERT + MLP):**

Ventajas: Extrae señales predictivas latentes de texto no estructurado (evaluaciones y consejería); al combinarse con MLP para datos estructurados, alcanza métricas superiores de F1-Score y Accuracy.

Desventajas: Alta complejidad de infraestructura (requiere GPUs para fine-tuning) y mayor dificultad de integración técnica en tiempo real.

- **Clasificadores Tradicionales (Decision Tree, Reg. Logística):**

Ventajas: Reglas de umbral simple (ej. GPA < 60% y asistencia < 70%) ofrecen máxima interpretabilidad y bajísimo costo de implementación.

Desventajas: Incapaces de capturar relaciones complejas no lineales, generando altas tasas de falsos positivos o falsos negativos.

- **Técnicas de Balanceo y Ensamble (ADASYN, SMOTE, Stacking):**

Ventajas: ADASYN/SMOTE balancean sintéticamente la clase minoritaria estabilizando el Recall. Ensemble Stacking alcanza la mayor discriminación predictiva (AUC ~0.938).

Desventajas: Mayor complejidad de arquitectura, despliegue y mantenimiento operativo en producción.

1.3 Matriz Comparativa de Literatura y Patentes

Resumen estructurado de las 10 fuentes analizadas en la investigación:

Documento / Patente	Enfoque / Problema Específico	Variables Clave Extraídas	Algoritmo Principal
McMahon & Sembiante (in press)	Revisión crítica para conectar predicción con intervención oportuna.	Académicas, comportamiento, actitudes y demográficas.	Growth Mixture Modeling / Síntesis
Bianchi et al. (2025)	Marco AIEWSF y evaluación de respuesta del asesor ante alertas.	LMS, notas previas, estrés financiero, ausencias, texto de alertas.	Ensemble Stacking + Aumento LLM
JUTIF / Univ. XYZ (2026)	Predicción de graduación tardía y deserción con datos desbalanceados.	GPA (IPK), repeticiones, ausencias, colegio, finanzas familiares.	Random Forest + ADASYN

Documento / Patente	Enfoque / Problema Específico	Variables Clave Extraídas	Algoritmo Principal
Balas (2025)	Marco bibliométrico y arquitectura X-EWS de 5 capas explicables.	Créditos aprobados, pago de matrícula, edad, beca.	Gradient Boosting + SHAP
Zhao & Ren	Alerta temprana basada en datos conductuales complejos.	GPA, tensión financiera, integración social, salud mental.	Random Forest (vs Regresión Logística)
Patente KR20240044572A	Predicción multimodal integrando registros académicos y texto libre.	Notas, becas, voluntariado + texto de evaluaciones y consejería.	Red Híbrida: KoBERT + MLP
Koreano.pdf	Marco de IA multimodal para alertas de deserción universitaria.	Tablas académicas, becas, traslados + evaluaciones de cursos.	KoBERT (Attention) + MLP
Patente US20250131520A1	Plataforma e interfaz interactiva para listas de vigilancia (watchlists).	Admisión, académicas (créditos AP), financieras, logs LMS.	XGBoost / Ensemble Submódulos
Carballo-Mendívil et al. (2025)	Predicción desde el día 0 usando exclusivamente datos de ingreso.	Edad, GPA preparatoria, admisión condicional, transporte.	XGBoost (Cutoff F1 = 0.338)
Bañeres et al. (2023)	Detección dinámica de riesgo a nivel de actividad evaluable (DTWin).	Cursos, repeticiones, GPA, entregas de tareas, clics VLE.	PDAR (Árboles + Ventanas DTWin)

2. PARTE II: PROPUESTA DE ARQUITECTURA DE SOFTWARE PARA EL SEMILLERO

2.1 Estrategia de Datos Mínimos Viables (MVP)

Para construir un prototipo funcional de despliegue rápido sin depender de integraciones institucionales complejas, se seleccionan **6 variables críticas de alta disponibilidad**:

- **1. Promedio de Educación Secundaria (High School GPA):** Captura el rendimiento académico previo e historial de preparación.
- **2. Edad al momento de la matrícula:** Indicador de trayectoria no lineal o mayores responsabilidades socio-laborales.
- **3. Condición de Admisión:** Permite identificar estudiantes matriculados bajo programas de nivelación o prueba.
- **4. Promedio Acumulado Universitario (GPA/IPK):** Métrica directa del desempeño académico actual.
- **5. Asignaturas o Créditos Repetidos/Reprobados:** Indicador de acumulación de rezago curricular.
- **6. Frecuencia de Inasistencias o Registros LMS (Clickstream):** Señal conductual en tiempo real del nivel de compromiso del estudiante.

2.2 Lógica de Detección e Intervención en Producción

El diseño operacional del sistema se fundamenta en tres componentes clave:

- **Dashboard con Semáforo y Explicabilidad SHAP:** Las alertas se estructuran en verde (bajo riesgo), amarillo (riesgo moderado) y rojo (alerta crítica). Cada estudiante seleccionado despliega una ficha con la contribución exacta de sus variables vía valores SHAP.

- **Control de Fatiga de Notificaciones (DTWin):** Se implementan Ventanas Temporales Dinámicas. La alerta roja solo se dispara si el patrón de riesgo persiste durante *N* días consecutivos, evitando saturación por inactividad puntual.
- **Generación de Narrativas Contextuales mediante LLM:** En lugar de enviar un puntaje frío (ej. 'Riesgo 0.81'), un modelo sintético traduce el perfil a un resumen ejecutivo en lenguaje natural (ej. 'El estudiante X redujo su interacción en Canvas un 60% en las últimas 2 semanas'). La literatura demuestra que este enfoque incrementa la tasa de respuesta del tutor del **64.8% al 84.2%** y reduce el tiempo de contacto de 8.4 a **3.2 días**.

2.3 Directrices Éticas, Legales y Gobernanza de Datos

Para garantizar el cumplimiento normativo y proteger a la comunidad estudiantil, el sistema se regirá por los siguientes principios:

- **Consentimiento Informado y Transparencia:** Inclusión de cláusula explícita en la matrícula para el tratamiento de datos académicos con fines de acompañamiento, ofreciendo opción de opt-out.
- **Encuadre de Apoyo No Estigmatizante (Supportive Framing):** Queda prohibido etiquetar estudiantes como 'En Riesgo de Deserción' en interfaces docentes. La comunicación se encuadra como 'Acompañamiento Académico Preventivo' (+28.4% de receptividad).
- **Auditorías de Equidad Algorítmica:** Evaluación periódica de métricas de Equalized Odds para verificar que el modelo no genere sesgos por género, edad o nivel socioeconómico.
- **Seudonimización y Minimización:** Uso de identificadores hasheados durante el entrenamiento del modelo, restringiendo el acceso a datos personales únicamente a tutores autorizados.

2.4 Ventaja Competitiva: Solución al 'Prediction-Action Gap'

La gran mayoría de los sistemas EWS comerciales y académicos fracasan en la práctica debido a la **Brecha entre Predicción y Acción**: generan modelos precisos pero entregan reportes opacos que los docentes ignoran.

> **La propuesta innovadora de nuestro semillero radica en la integración tripartita:** un motor predictivo robusto (XGBoost/RF) + un controlador dinámico de alertas (DTWin) + un generador de narrativas contextuales (LLM). Al entregar al docente una sugerencia de acción cualitativa y comprensible en lugar de un número abstracto, resolvemos el cuello de botella operativo, logrando que la institución verdaderamente intervenga y prevenga la deserción.